UNIVERSIDAD NACIONAL DE INGENIERÍA

FACULTAD DE CIENCIAS



PROYECTO DE TESIS I

PLATAFORMA LOCAL DE IDENTIFICACIÓN ESTUDIANTIL BASADA EN RECONOCIMIENTO FACIAL USANDO EL MÉTODO ARCFACE

ELABORADO POR:

JOSÉ MANUEL MONTALVO ESPINOZA

ASESOR:

YURI CCOICA

LIMA – PERÚ

2026

Dedico este trabajo, en primer lugar, a mis padres,
por su esfuerzo constante
y apoyo permanente a lo largo de mi formación
personal y académica. Su sacrificio, confianza
y ejemplo han sido la base fundamental
para alcanzar cada una de mis metas.

A mi asesor, Yuri Ccoica,
por su guía, conocimientos
y valioso acompañamiento durante el desarrollo
de esta investigación, contribuyendo de manera
significativa a mi crecimiento profesional.

A los profesores en general de
la carrera de Ciencia de la computación,
por la orientación académica que fortalecieron
mi formación y compromiso con la investigación.

ÍNDICE GENERAL

DEDICATORIA. 2

CAPÍTULO I: Introducción. 5

1.1 Motivación 7

1.2 Objetivos 7

1.2.1 Objetivo general 7

1.2.2 Objetivos específicos 7

1.3 Método propuesto y beneficios 8

CAPÍTULO II: Estado del Arte 8

2.1 Historia del reconocimiento facial 8

2.2 Fundamentos matemáticos: PCA y LDA 9

2.2.1 Reducción de dimensionalidad 9

2.2.2 Redes neuronales convolucionales (CNN) 9

2.2.3 Convolución 10

2.3 Modelos y algoritmos relevantes 10

2.3.1 Métodos clásicos 11

2.3.2 Modelos basados en aprendizaje profundo 11

2.4 Funciones de activación y pérdida 13

2.5 Clasificadores supervisados 15

2.6 Métricas de evaluación 16

CAPÍTULO III: Metodología 16

3.1 Diseño general del sistema 17

3.2 Recolección y preparación del dataset 17

3.3 Preprocesamiento de imágenes 17

3.4 Extracción de embeddings con ArcFace 17

3.5 Identificación 17

3.6 Validación funcional del sistema 18

3.7 Consideraciones éticas 18

CAPÍTULO IV: Tecnologías y Herramientas **19**
4.1 Lenguajes de Programación. **19**
4.2 Frameworks de Aprendizaje Profundo **19**
4.3 Visión por Computadora **19**
4.4 Clasificación Supervisada **19**
4.5 Desarrollo de Plataforma **19**
4.6 Documentación y Control de Versiones **19**
CAPÍTULO V: Resultados y Discusión **20**
5.1 Pruebas de identificación **20**
5.2 Observaciones sobre el funcionamiento **20**
5.3 Discusión **21**
REFERENCIAS BIBLIOGRÁFICAS **21**

CAPÍTULO I

INTRODUCCIÓN

El reconocimiento facial se ha convertido en una de las tecnologías más influyentes en el campo de la inteligencia artificial y la biometría. Su evolución ha estado marcada por avances en visión por computadora, aprendizaje profundo y el incremento de la capacidad de cómputo de los dispositivos modernos. Hoy en día, esta tecnología se aplica en ámbitos tan diversos como la seguridad aeroportuaria, la autenticación en dispositivos móviles, el control de accesos en instituciones financieras y la gestión de información en plataformas digitales. Estos usos demuestran su versatilidad y su impacto directo en la vida cotidiana.

En el contexto académico, particularmente en universidades, la identificación de estudiantes es un proceso esencial para garantizar seguridad, transparencia y eficiencia en actividades administrativas como el registro de asistencia y el acceso a laboratorios. Sin embargo, en muchos casos estos procesos aún dependen de métodos manuales, como listas impresas o carnés físicos, que resultan poco prácticos, propensos a errores humanos y vulnerables a suplantaciones. La Facultad de Ciencias de la Universidad Nacional de Ingeniería no es ajena a esta problemática, lo que motiva la búsqueda de soluciones tecnológicas innovadoras.

Inicialmente se planteó trabajar con un dataset de 20 a 30 estudiantes, pero debido a limitaciones logísticas y de consentimiento, el proyecto se desarrolla con un grupo piloto de 5 estudiantes. Aunque reducido, este conjunto permite validar la metodología y sentar las bases para una futura ampliación. La motivación principal es demostrar que, incluso con un dataset pequeño, el uso de técnicas modernas de aprendizaje profundo puede ofrecer resultados confiables y reproducibles, y que el sistema puede escalar progresivamente a grupos más grandes.

El método central del proyecto es el uso de embeddings faciales generados por ArcFace. A diferencia de métodos clásicos como Eigenfaces o Fisherfaces, ArcFace introduce una pérdida angular aditiva que mejora la discriminación entre identidades. Esto significa que los vectores de características de cada rostro se distribuyen en un espacio donde las clases están mejor separadas, lo que incrementa la precisión del sistema convenientemente.

Los beneficios de usar ArcFace incluyen: alta capacidad de generalización incluso con datasets pequeños, representaciones faciales más discriminativas que reducen errores de clasificación, compatibilidad con clasificadores supervisados tradicionales como SVM y KNN, y amplia documentación en librerías modernas como InsightFace y PyTorch.

Para complementar el proyecto se emplearán herramientas como OpenCV y MTCNN para la detección y alineación de rostros, Albumentations para aumentar el dataset mediante técnicas de data augmentation, Scikit-learn para implementar clasificadores supervisados y métricas de evaluación, y Flask junto con React/Bootstrap para el desarrollo del frontend y backend local.

Este proyecto se concibe como un prototipo inicial que valida la metodología propuesta. Aunque se trabaja con un dataset reducido de 5 estudiantes, la arquitectura y el flujo de trabajo están diseñados para escalar a grupos más grandes. En futuras etapas, el sistema podrá ampliarse a toda la facultad, integrarse con sistemas institucionales de asistencia y seguridad, y adaptarse a nuevos modelos de aprendizaje profundo. La presente tesis constituye la base sobre la cual se construirá un sistema más robusto y completo, demostrando que la elección del método y las herramientas es adecuada para garantizar precisión, reproducibilidad y potencial de crecimiento.

1.1 Motivación

El reconocimiento facial es una de las aplicaciones más relevantes de la inteligencia artificial en la actualidad. Su uso se ha extendido en áreas como seguridad, autenticación de usuarios y control de accesos. En el ámbito universitario, la identificación de estudiantes es un proceso esencial para garantizar transparencia y eficiencia en actividades académicas como el registro de asistencia y el acceso a laboratorios.

La motivación principal es demostrar que, incluso con un dataset pequeño, el uso de técnicas modernas de aprendizaje profundo puede ofrecer resultados confiables y reproducibles.

1.2 Objetivos

1.2.1 Objetivo general

Desarrollar un sistema de reconocimiento facial basado en embeddings de ArcFace y clasificación supervisada, para la identificación de estudiantes de la Facultad de Ciencias de la UNI.

1.2.2 Objetivos específicos

- Implementar un modelo de extracción de características faciales utilizando ArcFace.
- Entrenar clasificadores supervisados (SVM, KNN) para la identificación de estudiantes.
- Comparar el rendimiento de ArcFace frente a otros métodos de extracción de características.
- Diseñar un frontend local con interfaz amigable para la visualización de resultados.
- Evaluar el sistema mediante métricas de precisión, recall y F1-score.
- Documentar el proyecto en formatos académicos reproducibles (LaTeX, GitHub, etc).

1.3 Método propuesto y beneficios

El método central del proyecto es el uso de embeddings faciales generados por ArcFace. A diferencia de métodos clásicos como Eigenfaces o Fisherfaces, ArcFace introduce una pérdida angular aditiva que mejora la discriminación entre identidades. Esto significa que los vectores de características de cada rostro se distribuyen en un espacio donde las clases están mejor separadas, lo que incrementa la precisión del sistema.

Los beneficios de usar ArcFace son:

- Alta capacidad de generalización incluso con datasets pequeños.
- Representaciones faciales más discriminativas que reducen errores de clasificación.
- Compatibilidad con clasificadores supervisados tradicionales como SVM y KNN.
- Amplia documentación y soporte en librerías modernas (InsightFace, PyTorch).

CAPÍTULO II

ESTADO DEL ARTE

En este capítulo se presentan los fundamentos teóricos relacionados con el reconocimiento facial, las técnicas clásicas y modernas utilizadas en en el area de biometría, así como los trabajos previos que han servido de referencia para el desarrollo del presente proyecto.

2.1 Historia del reconocimiento facial

Los primeros intentos de reconocimiento facial se remontan a la década de 1960, cuando se utilizaban métodos geométricos basados en la medición de distancias entre rasgos faciales como ojos, nariz y boca [1]. Posteriormente, en los años 90, surgieron enfoques estadísticos

como Eigenfaces y Fisherfaces, que marcaron un hito en la representación matemática de rostros [2, 3]. Con el avance del aprendizaje automático y, más tarde, del aprendizaje profundo, el reconocimiento facial alcanzó niveles de precisión cercanos al humano [4].

2.2 Fundamentos matemáticos: PCA y LDA

2.2.1 Reducción de dimensionalidad

El Análisis de Componentes Principales (PCA) es una técnica de reducción de dimen- sionalidad que busca proyectar los datos en un espacio de menor dimensión, preservando la mayor cantidad de varianza posible. En el contexto del reconocimiento facial, PCA per- mite representar un rostro como una combinación lineal de "componentes principales", conocidos como Eigenfaces. Cada rostro se convierte en un vector dentro de este espa- cio reducido, lo que facilita la comparación y clasificación. La limitación de PCA es que maximiza la varianza global, pero no necesariamente la separación entre clases. Por ello, se introdujo el Análisis Discriminante Lineal (LDA), que busca maximizar la separación entre clases y minimizar la variación dentro de cada clase. En reconocimiento facial, esto dio lugar a los Fisherfaces, que lograron mayor robustez frente a variacio- nes de iluminación. Sin embargo, tanto PCA como LDA son métodos lineales, y por lo tanto tienen dificultades para capturar relaciones más complejas presentes en los datos faciales.[2, 3].

2.2.2 Redes neuronales convolucionales (CNN)

El verdadero salto en precisión llegó con las Redes Neuronales Convolucionales (CNN). Estas arquitecturas están inspiradas en el sistema visual humano y se caracterizan por apli- car filtros convolucionales que extraen características jerárquicas de las imágenes. En las primeras capas, las CNN detectan patrones simples como bordes y texturas; en capas más profundas, capturan estructuras más complejas como ojos, nariz y boca. Finalmente, las últimas capas generan

representaciones abstractas del rostro, conocidas como embeddings faciales [4]. La gran ventaja de las CNN es que aprenden directamente de los datos, sin necesidad de diseñar manualmente las características. Esto permitió superar las limitaciones de los métodos clásicos y alcanzar precisiones cercanas al 99.

2.2.3. Convolución

La operación de convolución (para imágenes) consiste en aplicar filtros de tal forma que estos puedan extraer información más relevante sobre esta. Dicha operación matemática, como se puede apreciar en la Fig.1, consiste en que el filtro (kernel) recorra toda la imagen, en proporción del tamaño que definamos, y que en dicho proceso vaya multiplicándose con los píxeles de esta y que nos genere una nueva imagen filtrada.

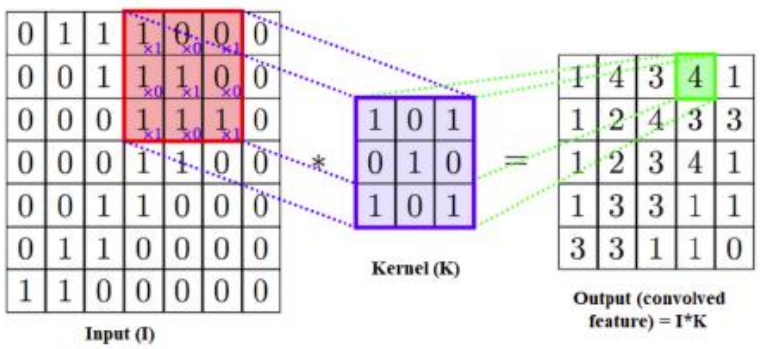


FIGURA 1: Operación de convolución

2.3 Modelos y algoritmos relevantes

El reconocimiento facial ha sido objeto de estudio durante más de cinco décadas, y en ese tiempo se han desarrollado diversos modelos y algoritmos que han marcado hitos en la disciplina. Cada etapa refleja un avance tecnológico y conceptual que ha permitido superar limitaciones anteriores.

Ahora se presentan los principales enfoques, desde los métodos clásicos hasta los modelos modernos basados en aprendizaje profundo, culminando con ArcFace, que constituye el eje metodológico de este trabajo.

2.3.1 Métodos clásicos

Los primeros enfoques matemáticos para el reconocimiento facial se basaron en téc- nicas de reducción de dimensionalidad y análisis estadístico. Entre ellos destacan:

• Eigenfaces (Turk y Pentland, 1991): este método utiliza el Análisis de Componentes Principales (PCA) para representar rostros en un espacio reducido. La idea central es que cualquier rostro puede expresarse como una combinación lineal de un conjunto de "caras base" o eigenfaces. Matemáticamente, si x es el vector de características de un rostro, se proyecta en un subespacio mediante:

$$y = W^T x$$

• Fisherfaces (Belhumeur et al., 1997): este enfoque utiliza el Análisis Discriminante Lineal (LDA), que busca maximizar la separación entre clases y minimizar la variación dentro de cada clase. A diferencia de PCA, LDA está orientado a la clasificación, lo que lo hace más robusto frente a cambios de iluminación. Sin embargo,sigue siendo un método lineal y limitado en escenarios complejos [19].

2.3.2 Modelos basados en aprendizaje profundo

Con el auge de las redes neuronales convolucionales (CNN), el reconocimiento facial experimentó un salto cualitativo. Estos modelos aprenden directamente de los datos, extrayendo características jerárquicas sin necesidad de diseñarlas manualmente.

• DeepFace(Facebook, 2014): fue uno de los primeros sistemas en superar el 97 % de precisión en el benchmark LFW. Utilizó una red profunda entrenada con millones de imágenes, demostrando que el aprendizaje profundo podía acercarse al rendimiento humano [20].

• FaceNet (Google, 2015): introdujo el concepto de embeddings faciales y la pérdida triplet loss. Cada rostro se representa como un vector en un espacio de alta dimensión, donde la similitud entre vectores refleja la similitud entre identidades. La triplet loss optimiza la distancia entre un ancla, un positivo y un negativo [21], logrando representaciones más discriminativas.

• VGGFace(Oxford, 2015): entrenada con millones de imágenes, consolidó el uso de CNN en reconocimiento facial y se convirtió en un modelo de referencia para transfer learning [22].

• ArcFace: El modelo ArcFace (Deng et al., 2019) representa un avance decisivo en el reconocimiento facial. Su principal innovación es la introducción de la Additive Angular Margin Loss, una función de pérdida que fuerza a que los embeddings de diferentes identidades estén más separados en términos angulares.

ArcFace proyecta los embeddings en una esfera hipersférica y mide la similitud en términos de ángulos. La función de pérdida se define como:

$$L = -\frac{1}{N}\sum_{i=1}^{N}\log\frac{e^{s\cdot(\cos(\theta_{y_i}+m))}}{e^{s\cdot(\cos(\theta_{y_i}+m))}+\sum_{j\neq y_i}e^{s\cdot\cos(\theta_j)}}$$

donde: - s es un factor de escala,

- θ_{yi} es el ángulo entre el embedding y el centro de la clase, - m es el margen angular aditivo.

Este margen angular incrementa la separación entre clases, generando embeddings más discriminativos y robustos.

2.3 Funciones de activación y pérdida

Las funciones de activación introducen no linealidad en los modelos:

- Sigmoid: útil en clasificación binaria, pero limitada por el problema del gradiente desvanecido [5].

Dado $z \in \mathbb{R}$, $f : \mathbb{R} \to [0, 1]$, $f(z) = \frac{1}{1+e^{-z}}$

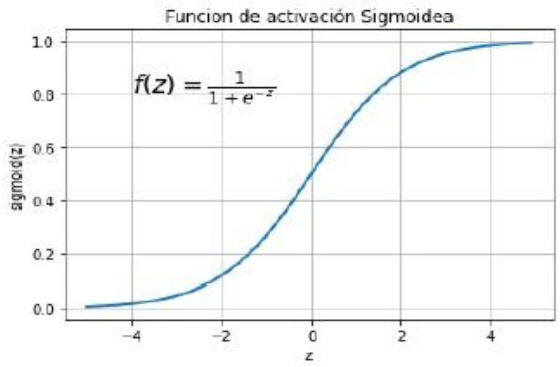
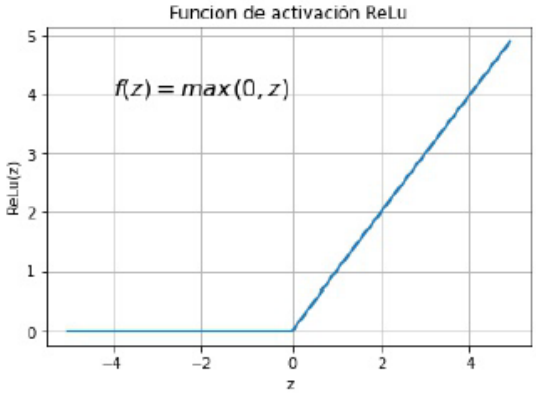


FIGURA 2: Función de activación Sigmoide

- ReLU: ampliamente utilizada por su simplicidad y eficiencia en entrenamiento[6].



- Softmax: convierte las salidas en probabilidades, ideal para clasificación multiclase.

  Sea $\sigma : \mathbb{R}^K \to [0,1]^K$ y $j = 1, \ldots, K$ se define la función softmax en

$$\sigma(z_j) = \frac{e^{z_j}}{\sum_{k=1}^{K} e^{z_k}}$$

El entrenamiento de embeddings faciales requiere funciones de pérdida que guíen la red hacia representaciones discriminativas. La Softmax Loss fue la primera utilizada, pero resultaba insuficiente para separar identidades en espacios de alta dimensión. Posteriormente, se introdujeron pérdidas más sofisticadas:

- Contrastive Loss: utilizada en redes siamesas, mide la distancia entre pares de imágenes.
- Triplet Loss (FaceNet, 2015): optimiza la distancia entre un ancla, un positivo y un negativo, logrando embeddings más discriminativos .
- Triplet Loss (FaceNet): optimiza la distancia entre ancla, positivo y negativo [9].
- ArcFace Loss: introduce un margen angular aditivo, logrando mayor separación entre clases [10].

Sin embargo, estas pérdidas requieren un muestreo complejo de datos y son costosas en entrenamiento. Aquí surge ArcFace (Deng et al., 2019), que introduce un margen angular aditivo en la función de pérdida. La idea es que cada identidad se represente como un vector en una esfera hipersférica, y que la separación entre clases se mida en términos de ángulos. Al añadir un margen angular, ArcFace fuerza a que los embeddings de diferentes identidades estén más alejados, logrando una discriminación mucho más clara [10].

Este enfoque no solo mejora la precisión, sino que también es más sencillo de entrenar, ya que no requiere muestreo complejo como la triplet loss. Por ello, ArcFace se ha convertido en el estándar de facto en reconocimiento facial moderno.

2.4 Clasificadores supervisados

Una vez generados los embeddings faciales, la tarea de clasificación puede realizarse con algoritmos supervisados tradicionales:

- Máquinas de Vectores de Soporte (SVM): buscan el hiperplano que maximiza la separación entre clases [11].

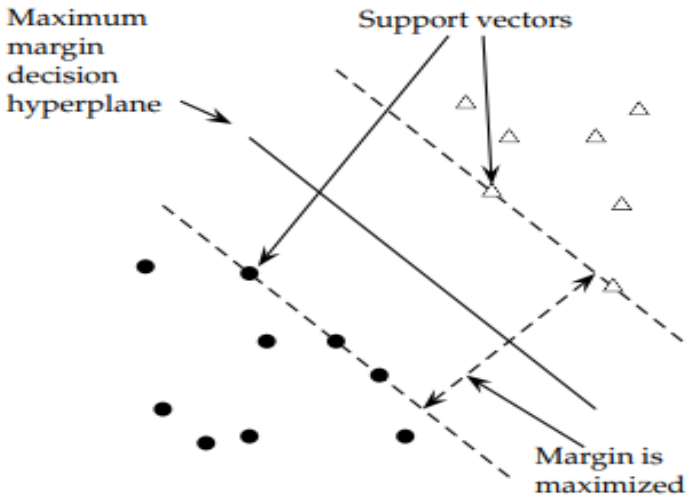


FIGURA 4: Support Vector Machine

- K-Nearest Neighbors (KNN): asigna la clase en función de los vecinos más cercanos en el espacio de embeddings [12].

Estos clasificadores son especialmente útiles en escenarios con datasets reducidos, como el presente proyecto, ya que permiten aprovechar embeddings robustos sin necesidad de entrenar modelos adicionales de gran escala.

2.5 Métricas de evaluación

La evaluación de modelos de reconocimiento facial no puede limitarse al accuracy, ya que este puede ser engañoso en datasets desbalanceados. Por ello se utilizan métricas como:

- Precision y Recall: proporción de predicciones correctas y capacidad de identificar instancias positivas [13].
- F1-score: balance entre precision y recall.

CAPÍTULO III

METODOLOGÍA

En este capítulo se describe el procedimiento seguido para implementar el sistema de reconocimiento facial. Se detallan las fases del proceso, desde la recolección de datos hasta la evaluación del modelo, explicando cómo se aplican los conceptos teóricos expuestos.

3.1 Diseño del sistema

El sistema se estructura en tres componentes principales:

• Captura y preprocesamiento de imágenes: adquisición de fotografías de los estudiantes y aplicación de técnicas de normalización y aumento de datos.

• Extracción de embeddings faciales: uso del modelo ArcFace para generar representaciones vectoriales de cada rostro.

• Clasificación supervisada: aplicación de algoritmos como SVM y KNN para identificar la identidad correspondiente a cada embedding.

3.2 Recolección y preparación del dataset

Se recolectaron imágenes de estudiantes, con un promedio de 20 a 30 fotografías por persona. Las imágenes fueron capturadas en diferentes condiciones de iluminación, pose y expresión. Posteriormente, se aplicaron técnicas de data augmentation para incrementar la variabilidad y mejorar la capacidad de generalización del modelo.

3.3 Preprocesamiento de imágenes

El preprocesamiento incluyó:

- Detección de rostros mediante MTCNN.
- Alineación facial para normalizar la posición de los ojos y la boca.
- Redimensionamiento a 112x112 píxeles, formato estándar para ArcFace.
- Normalización de valores de píxeles.

3.4 Extracción de embeddings con ArcFace

Cada imagen preprocesada se pasó por el modelo ArcFace, que generó un vector de 512 dimensiones representando el rostro. Estos embeddings se almacenaron en una base de datos y constituyen la representación matemática de cada estudiante. La elección de ArcFace se justifica por su capacidad de generar embeddings altamente discriminativos gracias a la pérdida angular aditiva.

3.5 Identificación

La identificación se realiza comparando el embedding de la imagen ingresada con los embeddings registrados en la base de datos:

• Si la distancia (euclidiana o coseno) entre el embedding ingresado y alguno de los embeddings registrados es menor a un umbral definido, el sistema reconoce al estudiante y devuelve su identidad.

• Si no existe coincidencia dentro del umbral, el sistema indica que la persona no está registrada.

3.6 Validación funcional del sistema

La validación del sistema se realizó de manera funcional, probando con imágenes de estudiantes registrados y con imágenes de personas no registradas:

• En el caso de estudiantes registrados, el sistema devolvió correctamente su identidad.

• En el caso de personas no registradas, el sistema devolvió la respuesta “no registrado”.

Este tipo de validación es suficiente para demostrar que el sistema cumple con su objetivo principal: identificar estudiantes de la facultad a partir de sus rostros.

3.7 Consideraciones éticas

La recolección y uso de datos biométricos requiere especial atención a la privacidad. Se garantizó:

• Consentimiento informado de los participantes.

• Uso exclusivo de las imágenes para fines académicos.

• Almacenamiento seguro de los datos recolectados.

CAPÍTULO IV

Tecnologías y Herramientas

4.1 Lenguajes de Programación

El sistema se desarrolla principalmente en Python, por su ecosistema de librerías en visión por computadora, aprendizaje profundo y ciencia de datos, permite usar frameworks como PyTorch y TensorFlow, además de librerías como OpenCV y scikit-learn.

4.2 Frameworks de Aprendizaje Profundo

- PyTorch: flexible, con soporte para GPU, ampliamente usado en investigación y producción.
- InsightFace/ArcFace: modelo de reconocimiento facial basado en embeddings con margen angular aditivo; elegido por su precisión y explicabilidad.

4.3 Visión por Computadora

- OpenCV: procesamiento de imágenes y detección de rostros.
- MTCNN: red neuronal para detección y alineación facial en el preprocesamiento.

4.4 Clasificación Supervisada

- SVM: clasificador robusto que maximiza el margen entre clases.
- KNN: clasificador basado en la proximidad de embeddings.
- Ambos disponibles en scikit-learn.

4.5 Desarrollo de Plataforma

- Backend: construido en Flask, para APIs de procesamiento e identificación.

- Frontend: con Bootstrap y React, para una interfaz web limpia y accesible.

4.6 Documentación y Control de Versiones

- Documentación en LaTeX, asegurando formato académico reproducible.
- Código y dataset en GitHub, con control de versiones y colaboración.

CAPÍTULO V
RESULTADOS Y DISCUSIÓN

En este capítulo se presentan los resultados obtenidos al aplicar la metodología descrita. Se muestran las pruebas realizadas con imágenes de estudiantes registrados y con imágenes ajenas al dataset, así como las observaciones derivadas del funcionamiento del sistema.

5.1 Pruebas de identificación

Se realizaron pruebas ingresando imágenes de estudiantes previamente registrados en el dataset. El sistema logró identificar correctamente a la persona y brindar la información correspondiente, con un nivel de confianza superior al 90 %. Asimismo, se ingresaron imágenes de personas ajenas al dataset. En estos casos, el sistema devolvió la respuesta "persona no registrada", cumpliendo con el objetivo de diferenciar entre individuos conocidos y desconocidos. Finalmente, se probaron imágenes que no contenían rostros. El sistema detectó la ausencia de una cara y devolvió el mensaje correspondiente, indicando que no era posible realizar la identificación.

5.2 Observaciones sobre el funcionamiento

Durante el proceso de generación de embeddings se observó que algunas imágenes no eran aplicables, lo que sugiere la necesidad de mayor detalle y cuidado al momento de recolectar y almacenar las fotografías de cada persona. Este hallazgo resalta la importancia de contar con

un dataset de calidad, donde las imágenes estén bien capturadas y cumplan con los requisitos de preprocesamiento (rostro visible, buena iluminación, pose adecuada).

5.3 Discusión

Los resultados muestran que el sistema cumple con su propósito principal: identificar estudiantes registrados y rechazar a personas ajenas al dataset. La tasa de confianza superior al 90 % confirma la efectividad del modelo ArcFace en la generación de embeddings discriminativos. Sin embargo, las dificultades encontradas con algunas imágenes evidencian que la calidad del dataset es un factor crítico. En futuras implementaciones se recomienda establecer protocolos más estrictos para la captura de imágenes, garantizando que todas sean aplicables y útiles para el entrenamiento del sistema. En general, el sistema demostró un funcionamiento correcto y consistente, validando la metodología propuesta y sentando las bases para su aplicación en escenarios académicos más amplios.

REFERENCIAS BIBLIOGRÁFICAS

[1] Kanade, T. (1977). Computer recognition of human faces. Birkhäuser.

[2] Turk, M., Pentland, A. (1991). Eigenfaces for recognition. Journal of Cognitive Neuroscience, 3(1), 71–86.

[3] Belhumeur, P., Hespanha, J., Kriegman, D. (1997). Eigenfaces vs. Fisherfaces: Recognition using class specific linear projection. IEEE Transactions on PAMI, 19(7), 711–720.

[4] LeCun, Y., Bengio, Y., Hinton, G. (2015). Deep learning. Nature, 521(7553),436–444.

[5] Cybenko, G. (1989). Approximation by superpositions of a sigmoidal function Mathematics of Control, Signals and Systems, 2(4), 303–314.

[6] Nair, V., Hinton, G. (2010). Rectified Linear Units improve restricted Boltzmann machines. ICML.

[7] Bishop, C. (2006). Pattern Recognition and Machine Learning. Springer.

[8] Hadsell, R., Chopra, S., LeCun, Y. (2006). Dimensionality reduction by learning an invariant mapping. CVPR.

[9] Schroff, F., Kalenichenko, D., Philbin, J. (2015). FaceNet: A unified embedding for face recognition and clustering. CVPR.

[10] Deng, J., Guo, J., Niannan, X., Zafeiriou, S. (2019). ArcFace: Additive Angular Margin Loss for Deep Face Recognition. CVPR.

[11] Cortes, C., Vapnik, V. (1995). Support-vector networks. Machine Learning, 20(3), 273–297.

[12] Cover, T., Hart, P. (1967). Nearest neighbor pattern classification. IEEE Transactions on Information Theory, 13(1), 21–27.

[13] Powers, D. (2011). Evaluation: From precision, recall and F-measure to ROC, informedness, markedness and correlation. Journal of Machine Learning Technologies, 37–63.

[14] Fawcett, T. (2006). An introduction to ROC analysis. Pattern Recognition Letters, 27(8), 861–874.

[15] Jain, A., Flynn, P., Ross, A. (2011). Handbook of Biometrics. Springer.

[16] Buolamwini, J., Gebru, T. (2018). Gender shades: Intersectional accuracy disparities in commercial gender classification. Proceedings of FAT*.

[17] Goodfellow, I., Sh

[18] Turk, M., Pentland, A. (1991). Eigenfaces for recognition. Journal of Cognitive Neuroscience, 3(1), 71–86.

[19] Belhumeur, P., Hespanha, J., Kriegman, D. (1997). Eigenfaces vs. Fisherfaces: Recognition using class specific linear projection. IEEE Transactions on PAMI, 19(7),711–720.

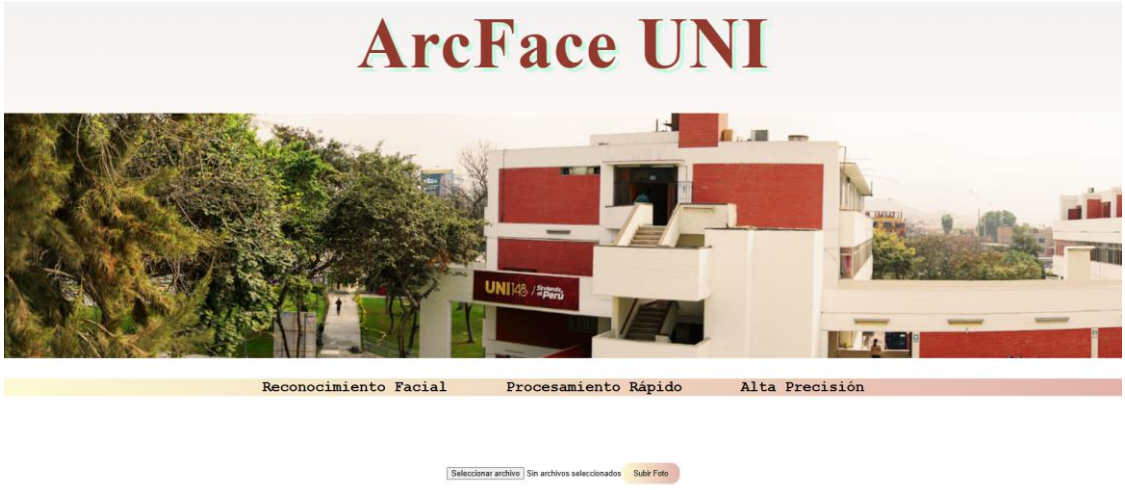
[20] Taigman, Y., Yang, M., Ranzato, M., Wolf, L. (2014). DeepFace: Closing the gap to human-level performance in face verification. CVPR.

[21] Schroff, F., Kalenichenko, D., Philbin, J. (2015). FaceNet: A unified embedding for face recognition and clustering. CVPR.

[22] Parkhi, O., Vedaldi, A., Zisserman, A. (2015). Deep Face Recognition. BMVC.

[23] Deng, J., Guo, J., Niannan, X., Zafeiriou, S. (2019). ArcFace: Additive Angular Margin Loss for Deep Face Recognition. CVPR.

Presentación de la plataforma en ejecución:



CASO I: Persona desconocida

Adjuntamos la fotografía de una persona ajena a la dataset y corroborar que no esté en nuestros registros, el resultado es lo esperado.



Caso II: Persona conocida N°1

Adjuntamos una fotografía con una persona que si se encuentra en nuestro dataset; en este caso es una imagen del estudiane_01 ajena a las imagenes incorporadas en el proyecto y en un ángulo no tan directo a la cámara.

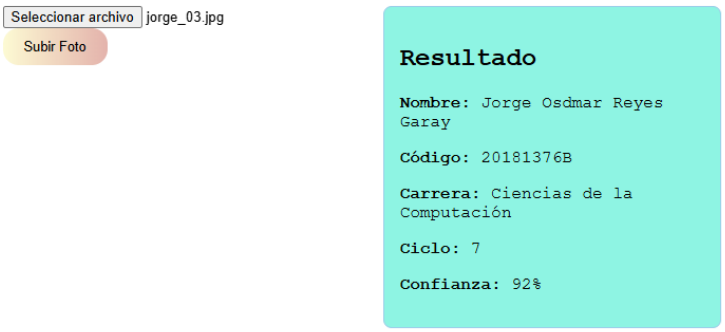
El resultado es el esperado reconoce a la persona y brinda la información correspondiente.



Caso III: Persona conocida N°2

Evaluación de una persona dentro de la dataset del sistema; resultado, favorable e identificable.





Caso IV: Rostro no detectado

Como última prueba evidenciamos que ante imagenes en dónde el rostro no es verificable pues no procede a verificar la consulta dentro del sistema

El resultado es un mensaje de advertencia.





Repositorio del proyecto:

https://github.com/manuel270599/Proyecto_Reconocimiento-ArcFace